

La Michoacana

FINSUS DATA CHALLENGE



Camilo Abboud, 2024

**“A process cannot be understood by stopping it.
Understanding must move with the flow of the
process, must join it and flow with it”.**

Frank Herbert, Dune

Problema

La Michoacana decidió instalar 4,000 máquinas expendedoras de paletas dentro de la Ciudad de México.

- La cantidad de paletas retiradas para cada máquina, cada día desde que empezó la operación (hace 5 años) hasta el día anterior.
- La cantidad de paletas disponibles en cada máquina, cada día (a final del día, medianoche) desde que empezó la operación (hace 5 años) hasta el día anterior.
- La capacidad, en cantidad de paletas, de cada máquina expendedora.
- El costo de surtir cada máquina (\$100).
- El costo de mantener una paleta por un día por máquina expendedora (\$1)

Contenido

Dado que se trata de un problema complejo con muchas partes, probablemente queden áreas de mejora en el modelo (Spoiler alert, las habrá).

Describir las partes que componen el sistema de forma aislada primeramente, resultará más ilustrativo que presentar el resultado directamente el final.

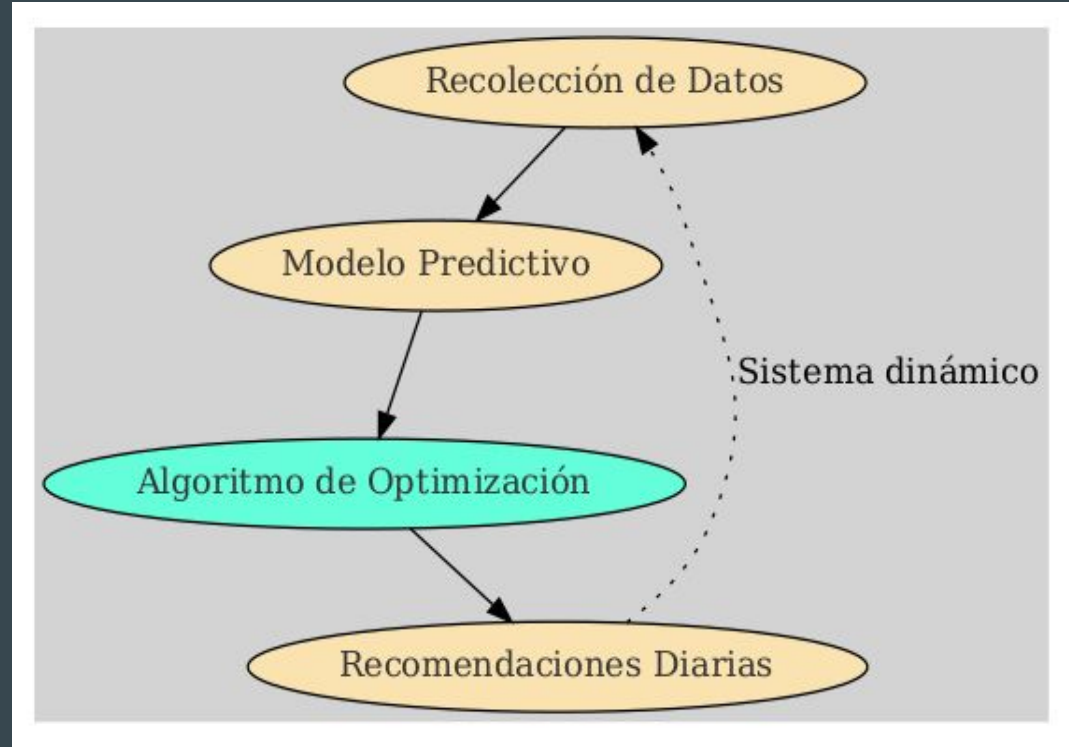
- 1- Las partes del proces
- 2- Riesgos, supuestos
- 3- Optimización Lineal
- 4- Forecast de demanda
- 5 - Simulación del proceso
- 6- Implementación

1- Las partes de proceso

Lo primero que me viene a la mente al leer el problema es que se trata de un problema de **optimización**.

Claro con lo que se está optimizando (programación lineal, algoritmos genéticos) depende de un modelo predictivo y que el resultado servirá para atender la operación diaria.

A su vez, todo este sistema debe iterar y ser retroalimentado.



Parte 2: Riesgos y Supuestos

2- Riesgos y supuestos

Supuestos

- Un supuesto importante es que los **datos históricos** y la **demanda futura** serán similares
- Otro supuesto es que los **costos operativo** s se conservarán constantes
- Estamos suponiendo que el consumo de paletas es independiente entre máquinas, cuando en realidad muy probablemente haya patrones de correlación (y causalidad!). Dicho en términos de retail, “canibalización”.
- Estamos hablando de un solo sabor de paletas, lo cual es poco probable

Riesgos

- Abuso del “*consumo infinito de paletas*”
- Error en el modelado podría llevar a distribución subóptima
- Discrepancias entre lo reportado y lo real en máquinas
- Daño y reparación de las máquinas
- Accidentes en los envíos

2.1 - Cambios al planteamiento

Sugerencia

- Debido al potencial abuso del consumo infinito, es que plantea adicionalmente al **modelo de suscripción** , otro modelo de **pay as you go**.
- La esencia del modelo no cambia mucho, sigue siendo un modelo de optimización, pero al incluir el ingreso por la venta de la paleta, indirectamente también podemos hacer ejercicios de *pricing* sobre el producto, permitiendo hacer estimaciones del *break-even* y demás métricas de viabilidad de producto a nivel teórico.
- También podríamos modelar el número de paletas vendidas en negativo como gasto variable, aunque no será en este ejercicio.
- Mantener los días insatisfechos por debajo del 2% lo cambiamos por un “castigo” traducido a costo si esto llegara a pasar.

Parte 3: Optimización Lineal

El problema de programación lineal para ambos modelos de negocio

Subscription

Minimizar

$$Z = \sum_{t=1}^T (C_s \cdot I_t + C_o + C_b \cdot B_t)$$

Sujeto a:

1. $I_t = I_{t-1} + Q_t - D_t, \quad \forall t$
2. $B_t = D_t - I_t, \quad \text{si } D_t > I_t$
 $B_t = 0, \quad \text{si } D_t \leq I_t$
3. $I_t \geq 0, \quad \forall t$
4. $Q_t \geq 0, \quad \forall t$

Variables de Decisión

1. Q : Cantidad de paletas a pedir (número de paletas).
2. I_t : Inventario en el tiempo t (número de paletas).
3. D_t : Demanda en el tiempo t (número de paletas).

Pay as you

g

Maximizar

$$Z = \sum_{t=1}^T (P \cdot D_t - C_s \cdot I_t - C_o - C_b \cdot B_t)$$

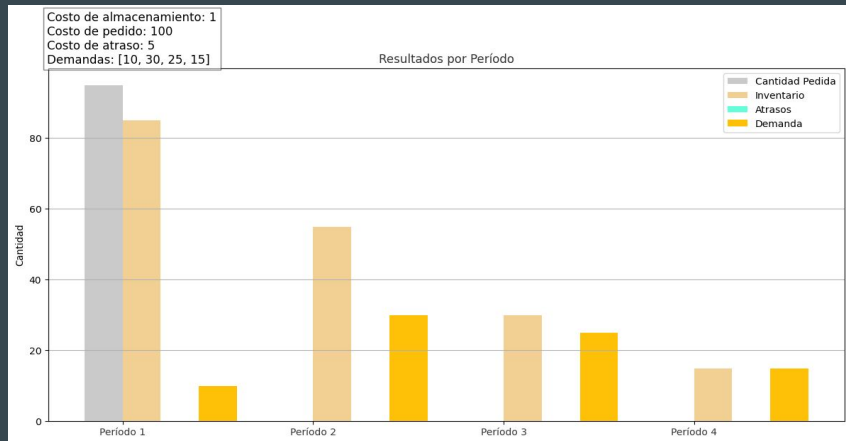

Sujeto a:

1. $I_t = I_{t-1} + Q_t - D_t, \quad \forall t$
2. $B_t = D_t - I_t, \quad \text{si } D_t > I_t$
 $B_t = 0, \quad \text{si } D_t \leq I_t$
3. $I_t \geq 0, \quad \forall t$
4. $Q_t \geq 0, \quad \forall t$

Donde:

- P : Precio de venta por paleta.
- C_s : Costo de almacenamiento por paleta.
- C_o : Costo fijo por pedido.
- C_b : Costo de atrasos por paleta no satisfecha.
- B_t : Atraso en la demanda en el tiempo t (si $D_t > I_t$).

Ejemplo del uso de programación lineal



- Luis sabe cual es la demanda futura
- El proceso dura 4 iteraciones (días, semanas o meses)
- El resultado es el mismo en ambos modelos de negocio (Suscripción y Pay as you Go)
- Inventario 0 en el tiempo 5
- Ejemplo para 1 máquina
- Al no haber diferencias entre el consumo real y el forecast, no hay retrasos

Si el volumen de venta lo amerita (Arriba), los pedidos pueden suceder en cada periodo, de lo contrario, será más eficiente una transportación única (Abajo).

Parte 4: Modelo Predictivo

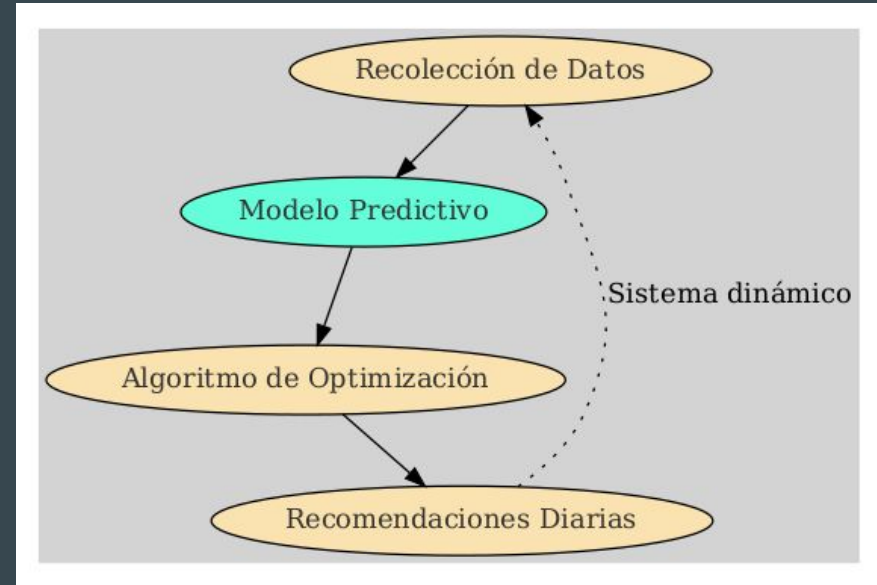
4 - El pronóstico de ventas

En la sección anterior, suponíamos cuál sería la demanda futura, pero ¿cómo la determinaremos?

El problema de inventarios y suministros se puede entender como un problema de **series de tiempo**.

Existen varios modelos, desde los más simples como *Holt-Winters*, los más populares como las *ARIMAS*, pasando por redes neuronales *LSTM*, que a su vez, se empiezan a quedar obsoletas con la llegada de arquitecturas con de gran capacidad de atención, como los *Transformers*.


Estos modelos tienen *parámetros* que bien pueden obedecer a una distribución, por lo que podríamos aplicar el paradigma bayesiano para actualizar el modelo iterativamente,



4.1 - ARIMAs, SARIMAs, SARIMAXs, et al

En la sección anterior, suponíamos cuál sería la demanda futura, pero ¿cómo la determinaremos? El problema de inventarios y suministros se puede entender como un problema de **series de tiempo**.

Con ARIMAS podemos entremezclar otras ideas, por ejemplo acá tenemos un componente anual y otro semanal sumados. De hecho eso es lo que vemos en la gráfica, una SARIMA con componente estacional de 7 días más otra componente exógena que es una una serie de fourier anual. (La primera vez que la uso) . Permitiendo gran expresividad por parte del modelo.



4.2 Los parámetros del modelo

Los datos ciertamente no son perfectos ni tan predecibles como en el ejemplo anterior.

No solo eso, tan solo el ejemplo anterior consta de 6 parámetros (p, d, q, s) + 2 harmónicos. ¿Cómo elegir los mejores? Yo generalmente uso el AIC o alguna variante.


Otra forma de elegir parámetros, o actualizarlos, más bien, sería con el paradigma bayesiano. Nuevos datos actualizan las creencias del modelo, pero este tema queda del alcance de este ejercicio.

Resumiendo: Ya tenemos un modelo de optimización y una forma de pronosticar demandas futuras, pero podemos hacer algo más...

Parte 5: Simulación

5. Simulaciones

Las simulaciones son nuestras grandes aliadas cuando no contamos con mucha información. También son muy útiles para resolver problemas muy complejos, que es precisamente nuestro caso. Es por ello que comparto un ejemplo para 2 máquinas y el efecto total. Este es solo un ejemplo para demanda hard-coded, pero la idea es inyectar el forecast aquí. Si el problema gana aún más complejidad, por ejemplo, tener varios sabores, las simulaciones podrían resolver el nuevo problema sin mucho más complicación. También ayuda a generar varios escenarios sin mayor problema.



Parte 6: Implementación

6.1-Implementación

¿Qué métricas evaluarías durante el desarrollo de la solución?

- Inventarios: Los días de inventario o la rotación de inventario ¿Es suficiente? ¿No se vende?
- Forecast: RMSE me gusta porque conserva las unidades, dependerá del caso específico, por supuesto.
- Reparto: Puntualidad, Exactitud (¿Cómo sabemos cuál realmente el inventario?)

¿Cómo te imaginas el despliegue y la operación en producción de la solución?

- Creo que la solución sería muy riesgosa sin algún tipo de tecnología IOT que entregue información de lo que está pasando dentro de la máquina y alrededor de ella. La seguridad y buen estado funcional y estético de la máquina.
- 4,000 máquinas con 5 años de información puede que empiece a ser algo que una computadora “normal” no pueda resolver... y ciertamente no es necesario ni correcto que un proceso automatizable corra en máquina local.
- Cambios al modelo deben de liberarse con cautela y evaluar distintas alternativas (Canary release, Blue-Green, etc.). Para ello es indispensable contar con más de una instancia de las bases de datos implicadas en el proceso.

6.2-Implementación

¿Cómo evaluarías si la solución tuvo un impacto positivo y fue exitosa?

- Los costos operativos deberían de bajar tras optimizar la toma decisiones
- Las métricas de negocio están sanas (financieras y operativas). El proyecto es autónomo económicamente.
- Se toman decisiones importantes acerca de la operación ¿Vale la pena mantener las 4,000 máquinas? ¿Hay posibilidad de expandirse a otros estados? ¿Más sabores?

Conclusiones

Detectamos las partes más relevantes del problema y algunas formas específicas de cómo atacarlo.

Para optimización elegimos la optimización lineal. Para el pronóstico de demanda ARIMAs+. Incluso podemos inyectar estas partes como módulos de un **proceso de simulación** que nos puede permitir medir y prever el impacto total para nuestro escenario esperado y muchos más.

Por último, nos imaginamos cómo se debería de ver y usar el modelo una vez terminado. Y nos cuestionamos acerca de cómo debería de verse el proyecto al darle seguimiento y qué partes quizás no estábamos considerando.

Gracias!



Camilo Abboud